

Análisis de Clusteres en Vinos mediante PCA y K-Means

Delfina Solís, Thiago Corte

26 de diciembre de 2025

Resumen

En el siguiente informe se presenta el estudio y la aplicación de técnicas de reducción y clustering para identificar grupos de vinos para el dataset presentado. Se utilizó el método de PCA para reducir la dimensionalidad, para luego aplicar el método de K-means sobre las componentes principales. Para poder obtener la cantidad óptima de clusters se utilizaron los métodos del codo (inerzia) y silhouette score, sumado a una inspección visual de la separación proyectada, por lo que se concluyó que el número óptimo era de dos clusters. La interpretación de los clusters se realizó relacionando los promedios de las componentes principales por cluster con las variables originales más relevantes, identificando diferencias claras en niveles de dióxido de azufre, densidad y contenido alcohólico entre los grupos.

1. Introducción

En este análisis se busca identificar agrupaciones de vinos a partir de algunas de sus propiedades utilizando técnicas de aprendizaje no supervisado. Se trabajó sobre un set de datos públicos de vinos, *Wine Data Set*, obtenido del *UCI Machine Learning Repository*.

El dataset cuenta con características como cantidad de alcohol, sulfatos, ph, acidez, entre otras. Se utilizó **PCA** para reducir la dimensionalidad del conjunto de datos y luego mediante el método de **K-means** se realizó la clusterización con el objetivo de encontrar grupos de vinos similares.

2. Preprocesamiento y PCA

El dataset utilizado contiene 6497 filas y 11 columnas con variables numéricas, dentro de las cuales está la cantidad de alcohol, el ph, los sulfatos, etc. Dado que K-Means utiliza la distancia euclídea como métrica principal, es importante reducir el ruido y la correlación entre los atributos. Luego de que se hayan escalado las variables mediante z-score, se realizó el análisis de componentes principales (PCA) para reducir las dimensiones manteniendo la mayor cantidad de información. El análisis de la varianza explicada mostró que con las primeras 9 componentes principales se conserva aproximadamente el 95 % de la varianza total del dataset. Teniendo en cuenta los resultados del PCA se transformaron los datos originales a este nuevo espacio reducido, sobre el cual ahora sí, se aplicó el algoritmo de K-means.

3. Determinación del número de clusters

Para la determinación de óptima de la cantidad óptima de clusters a utilizar en el método de K-means se utilizaron los métodos de *inerzia* y de *silhouette score*, lo cual se puede ver en los siguientes gráficos.

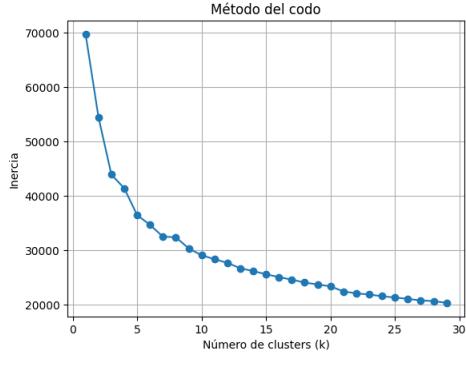


Figura 1: El gráfico muestra la inercia en función del número de clusters. El “codo” sugiere el punto a partir del cual añadir más clusters no mejora significativamente la compactación de los grupos.

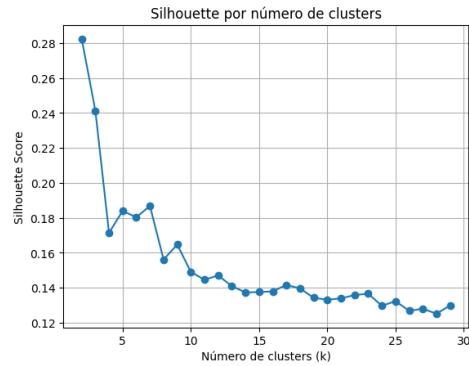


Figura 2: Evaluación del número óptimo de clusters mediante el silhouetted score. El número óptimo de clusters se asocia con el valor máximo del coeficiente.

Como ya se menciono, los graficos fueron generados a partir de las componentes principales obtenidas tras la reducción de dimensionalidad del PCA. Se puede observar en la 1 que para el metodo basado en la inercia el valor óptimo de los clusters es de 3, mientras que en el grafico 2 el metodo de silhouette score sugiere que el valor óptimo es de 2. Para decidir que clusterización utilizar se hizo una inspección visual de cada una de las clusterizaciones diferentes, con lo que se decidió que el valor óptimo debería ser el de 2 ya que ofrece una agrupación más clara y consistente. En el siguiente grafico 3 se puede observar el resultado de la clusterización más óptima obtenida utilizando el método de K-means para 2 clusters.

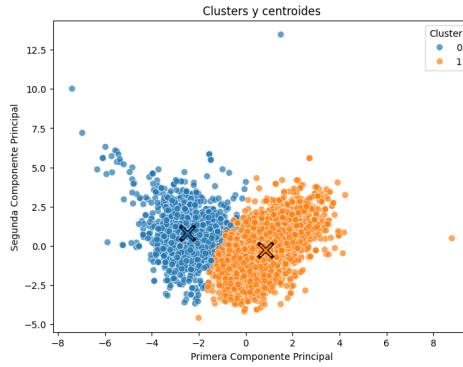


Figura 3: Clusters obtenidos por K-means proyectados sobre las dos primeras componentes principales. Los puntos están coloreados según su cluster y las cruces indican los centroides.

4. Clustering y Resultados

Una vez obtenidos los clusters, se calculó para cada uno el valor promedio de cada componente principal, lo que se puede ver en las cruces que se encuentran en los centroides de cada uno. Luego, se analizaron los coeficientes obtenidos para cada componente principal con respecto a las variables originales, para tener una relación entre ambos. Se aplicaron umbrales tanto para el promedio de la componente (umbral de 0.3) como para la magnitud de los loadings (umbral de 0.4), pudiendo así identificar las variables originales más relevantes de cada cluster, las cuales caracterizan de mejor manera a cada uno de estos. Se observó que para el cluster 0 se distingue por valores bajos en *free sulfur dioxide*, *total sulfur dioxide* y *densidad*, y un contenido *alcohólico* alto. Para el cluster 1 se obtienen altos niveles de *free sulfur dioxide*, *total sulfur dioxide* y *densidad*, al igual que en el cluster 0, pero

por otro lado, se tiene un menor nivel de *alcohol*, y diferencias significantes en *fixed acidity*, *citric acid* y *pH*.

5. Conclusiones

El uso combinado de PCA y K-means permitió agrupar eficazmente los vinos en dos clusters con características diferenciadas. La reducción de dimensionalidad facilitó el manejo de los datos permitiendo a la clusterización identificar grupos con propiedades claramente contrastantes, especialmente en relación con el dióxido de azufre, densidad y alcohol. Este enfoque demuestra la utilidad de combinar técnicas de reducción de dimensionalidad con clustering para el análisis exploratorio de los datos.

En conclusión, se puede decir que los métodos de PCA y K-means permitieron agrupar de la forma más efectiva y minimizando la cantidad de dimensiones a los vinos utilizando diferentes características de los mismos. La obtención de los mismos se facilitó debido a la reducción de la dimensionalidad permitiendo representar la mayor cantidad posible de datos con la menor cantidad de variables.